

Utilização de técnicas de inteligência computacional para estimar a pressão arterial a partir da fotopletismografia.

Alan Souza, Alex Assis, Douglas Marques, Roger Ferreira

Departamento de Pós Graduação em Engenharia Elétrica

Universidade Federal de Minas Gerais

Email: alancsouza04@gmail.com, assis.alex.d@gmail.com, tatudoug@gmail.com, rofes31@gmail.com

Abstract—O objetivo deste trabalho é aplicar técnicas de aprendizado de máquinas para estimar a pressão arterial a partir da base de dados de fotopletismografia. É realizado o tratamento da base de dados com um filtro passa baixa de 50Hz e a transformada rápida de Fourier (FFT) para utilizar os dados na rede neural ;COMPLETE AQUI;

1. Introdução

A elevação da pressão arterial (PA) é um dos fatores de risco para as doenças cardiovasculares que é a principal causa de morte mundial. A falta de informação e assistência para identificar as alterações da PA impede o diagnóstico dos fatores de risco e o início do tratamento. É relatado que metade dos casos de morte por hipertensão poderia ser revertido através de tratamento com antihipertensivos, quando identificada precocemente. [1]

A medição da pressão arterial, sistólica (SBP) e diastólica (DBP), é avaliada mecanicamente pela diferença de pressão entre um agente externo (o manguito apertando o braço) e a pressão dos vasos sanguíneos, desta forma é feita uma estimativa pela comparação das pressões. Uma alternativa para medição da pressão é usar um dispositivo não invasivo com a fotopletismografia (PPG) que pode realizar a leitura do batimento cardíaco distal (forma do sinal com a medida dos capilares do dedo) pela diferença de absorção de luz. [2]

Estudos de novos dispositivos vestíveis (*wearable*) são desenvolvidos com o objetivo de melhorar a qualidade do sinal PPG e explorar seu potencial para realizar medições do batimento cardíaco, propriedades vasculares periféricas, pressão arterial e atividades nervosas autônomas [3].

Técnicas para estimação da pressão sanguínea óptica batida-a-batida usando somente o sinal PPG das pontas dos dedos. As características cardíacas como amplitude e fase são extraídas da transformada rápida de Fourier (FFT). Os componentes extraídos da PPG serão entrada para uma rede neural artificial que fará a estimativa da pressão sanguínea [4].

Os fatores fisiológicos que justificam a estimação da pressão arterial através dos sinais de PPG são descritos pela viscosidade do sangue, parede arterial, hemodinâmica, síndrome metabólica, a idade, índice de massa corporal, a respiração e o sistema nervoso central. [2]

Métodos de aprendizado de máquinas (ML) tem sido propostos para estimação da pressão arterial de forma contínua e não invasiva através do sinal PPG. Alguns métodos de ML foram testados por Enric em [2] que utilizou como critério de seleção o coeficiente de determinação R^2 e para melhorar a performance do treinamento usou a validação cruzada. Na regressão linear (LR) utilizou o algoritmo de *ridge regression* para minimizar a soma dos quadrados dos resíduos (RSS) e a variabilidade dos atributos com performance $R_{SBP}^2 = 0.59$ e $R_{DBP}^2 = 0.53$, que corresponde respectivamente a pressão arterial sistólica e diastólica. A rede neural utilizada foi o perceptron de múltiplas camadas (MLP) com 10 neurônios na camada escondida e 3 neurônios na camada de saída que representa o nível de glicose no sangue (BGL), SBP e DBP, com a performance de $R_{SBP}^2 = 0.65$ e $R_{DBP}^2 = 0.63$. A SVM (*Support Vector Machine*) com regressão, função de perda ϵ -insensitiva e o *kernel* Gaussiano, com performance $R_{SBP}^2 = 0.72$ e $R_{DBP}^2 = 0.68$. Com *Random Forest* onde a saída do sistema é uma agregação das saída das árvores no treinamento foi utilizado *bootstrapping* e a seleção aleatória de características do teste em cada nó, a performance foi de $R_{SBP}^2 = 0.90$ e $R_{DBP}^2 = 0.86$. O método de melhor performance e estabilidade em relação a alteração dos dados foi *Random Forest*.

1.1. Motivação

Segundo a Organização Mundial de Saúde [5] 17.9 milhões de pessoas morreram em 2016 por doenças cardiovascular. O desenvolvimento de técnicas e dispositivos capazes de monitorar fatores de riscos, como a pressão arterial, para auxiliar no diagnóstico precoce de possíveis anormalidades. As redes neurais artificiais mostram se capazes de realizar boas aproximações da pressão arterial através da análise dos sinais de PPG. Para o bom desempenho da rede é necessários extrair e tratar as informações da PPG.

2. Revisão bibliográfica

2.1. Fotoplestimografia

Fotoplestimografia (PPG) é um método não invasivo de detecção do pulso de onda cardiovascular que propaga no

corpo. A onda cardiovascular é estimulada pela contração cardíaca detectada nos membros periféricos através de uma fonte de luz e um detector. [3] O sinal PPG é obtido pela iluminação da pele e a medição das mudanças de absorção da luz. A característica de interesse consiste em uma faixa de luz vermelha e uma faixa próxima a banda infravermelha. A diferença entre a mínima absorção depende do batimento cardíaco porque os vasos sanguíneos nos dedos expande e contrai com cada batimento. A diferença entre a absorção mínima e o pico de absorção da intensidade luminosa é proporcional ao pulso distal cardíaco. [2]

2.2. Técnicas de aprendizado de máquina

Problemas de aprendizado supervisionado são divididos em dois grupos: regressão e classificação. Dadas as características do problema de obtenção dos valores de pressão sanguínea, cujo objetivo é encontrar um valor real a partir dos dados disponíveis, o mesmo pode ser identificado como um problema de regressão.

Para alguns problemas mais complexos, ou dos quais dispõem de maior facilidade para coleta de dados em larga escala, comumente se aplicam modelos baseados em redes neurais de camadas profundas (*Deep Learning*) [6]. Dentre esses modelos, destacam-se redes neurais recorrentes [7] e modelos baseados em redes neurais convolucionais.

As redes neurais convolucionais (RNC), cuja arquitetura fora inicialmente proposta por [8], são redes neurais que usam a convolução no lugar da simples multiplicação de matrizes em pelo menos uma de suas camadas. As RNCs são especializadas em processamento de dados que possuem uma topologia em grade, como dados de séries temporais (grade 1D) e dados de imagem (grade 2D) [9]. A convolução é uma operação entre duas funções, definida como: a integral do produto de uma das funções, por uma cópia deslocada e invertida da outra, como mostrado em 1:

$$s(t) = (f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau \quad (1)$$

2.3. Transformada de Fourier

Para uma função n -dimensional $g(\vec{x})$, podemos definir a Transformada Contínua de Fourier [10]:

$$\hat{g}(\vec{k}) = \int d^n x g(\vec{x}) e^{-i\vec{x} \cdot \vec{k}} \quad (2)$$

A transformada inversa de Fourier é definida por:

3. Metodologia proposta

4. Pré-processamento dos dados

5. Extração de características

6. Modelo utilizado

7. Resultados

8. Conclusão

References

- [1] D. J. V. A. Kishore, Sandeep P; Heller, "Beyond hypertension: integrated cardiovascular care as a path to comprehensive primary care." *Bulletin of the World Health Organization*, 2018.
- [2] E. Monte-Moreno, "Non-invasive estimate of blood glucose and blood pressure from a photoplethysmograph by means of machine learning techniques," *Artificial Intelligence in Medicine*, 2011.
- [3] K. C. N. Eun Geun, Hyun Heo and Y. Huh, "Measurement site and applied pressure consideration in wrist photoplethysmography."
- [4] M. Xing, Xiaoman; Sun, "Optical blood pressure estimation with photoplethysmography and fft-based neural networks," *Biomedical Optics Express*, vol. 7, 2007.
- [5] W. health statistics, "Monitoring health for the sdgs, sustainable development goals." *journal*, 2018.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, p. 436, 2015.
- [7] T. Mikolov, M. Karafiát, L. Burget, J. Černocký, and S. Khudanpur, "Recurrent neural network based language model," in *Eleventh Annual Conference of the International Speech Communication Association*, 2010.
- [8] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [9] I. Goodfellow, Y. Bengio, A. Courville, and Y. Bengio, *Deep learning*. MIT press Cambridge, 2016, vol. 1.
- [10] A. V. ANAND, "A brief study of discrete and fast fourier transforms."